

2.1 理论计算题

2 多层感知机

2.1 理论计算题

1. 非线性激活函数的重要性

给定单隐藏层 MLP, 隐藏层无激活函数 (线性激活):

$$h = w_1 x + b_1 \quad o = w_2 h + b_2$$

将 h 代入输出:

$$o = w_2 (w_1 x + b_1) + b_2 = (w_2 w_1) x + (w_2 b_1 + b_2)$$

令 $w' = w_2 w_1, b' = w_2 b_1 + b_2$, 则:

$$o = w' x + b'$$

这是单层线性网络 (无隐藏层)。因此没有非线性激活函数的多层线性网络等价于单层线性网络, 无法增加表达能力。

2. 激活函数性质分析

Sigmoid 函数及其导数:

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}$$
$$\text{Sigmoid}'(x) = \text{Sigmoid}(x) \cdot (1 - \text{Sigmoid}(x))$$

Tanh 函数及其导数:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$
$$\tanh'(x) = 1 - \tanh^2(x)$$

3.1 理论计算题

1. 过拟合与欠拟合

训练误差: 模型在训练数据集上的平均损失 (或错误率)。

泛化误差: 模型在从未见过的测试数据集上的期望损失 (或错误率)。

当训练误差极低但泛化误差很高时, 模型处于过拟合状态。

缓解方法: 降低模型复杂度 (减少层数、神经元数、特征数)、使用正则化 (L1/L2、Dropout)、早停、数据增强、集成学习等。

2. K 折交叉验证

实施步骤:

(1) 将完整数据集随机打乱。

(2) 将数据集划分为 K 个大小相等的子集 (通常 $K=5$ 或 10)。

(3) 对于每个折 $i=1 \cdots K$:

将第 i 个子集作为验证集, 其余 $K-1$ 个子集合并作为训练集。

在训练集上训练模型, 在验证集上评估性能 (如准确率、MSE 等)。

(4) 计算 K 次评估结果的均值作为最终性能指标, 方差反映稳定性。

4.1 理论计算题

1. 梯度消失与梯度爆炸

深层网络反向传播时，梯度涉及多个 Jacobian 矩阵连乘：

$$\frac{\partial L}{\partial h^{(t)}} = \frac{\partial L}{\partial h^{(d)}} \prod_{i=t}^{d-1} \frac{\partial h^{(i+1)}}{\partial h^{(i)}}$$

每个 Jacobian $\frac{\partial h^{(i+1)}}{\partial h^{(i)}}$ 包含激活函数导数与权重矩阵的乘积。如果权重矩阵的谱半径大于 1 且激活函数导数也较大（如 ReLU 的正半轴导数为 1），连乘易导致梯度爆炸（数值极大）；如果权重矩阵谱半径小于 1 且激活函数导数小于 1（如 Sigmoid 最大 0.25），连乘导致梯度指数级衰减至 0，即梯度消失。

2. ReLU 缓解梯度消失的原因

ReLU 激活函数为 $f(x)=\max(0,x)$ ，其导数在正半轴恒为 1，负半轴为 0。因此在正向传播时，只要输入为正，梯度就可以无损地向后传递，不会像 Sigmoid/tanh 那样反复乘以小于 1 的数。这有效避免了梯度消失（虽然仍可能遇到神经元死亡问题）。

5.1 理论计算题

协变量偏移与标签偏移

协变量偏移 (Covariate Shift): 输入分布 $p(x)$ 发生变化，但条件分布 $p(y | x)$ 不变。即训练时某些特征出现的概率与测试时不同，但给定特征后标签的生成规则相同。

例子：医疗诊断系统训练数据来自年轻患者（症状分布 $p_{\text{train}}(x)$ 偏向年轻人群），测试时用于老年患者（ $p_{\text{test}}(x)$ 偏向老年）。但给定症状，疾病的概率 $p(y | x)$ 相同。

标签偏移 (Label Shift): 输出标签分布 $p(y)$ 发生变化，但条件分布 $p(x | y)$ 不变。即训练时不同类别的比例与测试时不同，但每个类别内部的输入特征分布相同。

例子：电商推荐系统训练时某类商品（如电子产品）销量高（ $p_{\text{train}}(y)$ 高），测试时该类商品销量降低，但购买电子产品的用户特征分布 $p(x | y)$ 不变。

联系：两者都是训练与测试分布不一致导致的领域漂移。区别在于偏移发生在输入还是输出上。实际中可能同时存在，需要更复杂的校正方法。